Dự báo khả năng mua của household

POC trên Dunnhumby Complete Journey theo CRISP-DM

Báo cáo project

November 9, 2026

Mục tiêu và phạm vi bài toán

- Ước lượng xác suất household phát sinh ít nhất một basket được ghi nhận trong 7 ngày sau cutoff.
- Tình huống giả định: retailer cần thông tin hỗ trợ dự báo hoặc sắp xếp ưu tiên household.
- Đơn vị phân tích: một household tại một cutoff; bao gồm fuel, miscellaneous và basket zero-sales.
- Kết quả dự báo hành vi được ghi nhận, chưa đo tác động của coupon hoặc liên hệ.

Tổng quan dữ liệu Dunnhumby

- 2.595.732 dòng transaction; 276.484 basket; 2.500 household; chỉ số ngày 1–711.
- Một dòng transaction là một sản phẩm trong basket; không đồng nhất số dòng với số chuyến mua.
- Bảng bổ trợ: product, demographic, campaign, coupon và product–store–week.
- Có demographic cho 801 household; thời điểm thông tin sẵn có trong lịch sử chưa được xác minh.

Chất lượng dữ liệu và giới hạn

- Hai ngày 278 và 643 có một basket mỗi ngày; nguyên nhân chưa được xác nhận.
- Không có ánh xạ đáng tin cậy từ `DAY` sang ngày lịch thực.
- Giữ `QUANTITY` trong nguồn nhưng không tổng hợp xuyên department do chưa rõ đơn vị.
- Demographic và marketing chưa dùng trong pipeline POC vì chưa rõ thời điểm sẵn có.
- Một household có thể xuất hiện tại nhiều cutoff; các quan sát không độc lập.

Thiết kế household–snapshot

- Tại cutoff s, dùng lịch sử đến hết s; target xét basket trong $(s, s+7]$.
- Chỉ xét household đã được ghi nhận đến cutoff; tạo snapshot theo tuần.
- Feature cơ bản: recency, thời gian quan sát và lịch sử basket, sales, số dòng, ngày hoạt động.
- Cửa sổ lịch sử 7, 30, 90 và 180 ngày; không dùng thông tin sau cutoff.

Phân chia theo thời gian

Tập	Cutoff	Household–snapshot
Train	180–537	129.834
Validation	551–621	27.480
Test	635–698	24.994

- Cutoff 544 và 628 là embargo; các nhãn giai đoạn trước trưởng thành trước giai đoạn sau.
- Test đã từng được xem trong quá trình phát triển: kết quả chỉ tham khảo cho POC.

Baseline và mô hình

- Baseline: xác suất mua theo sáu nhóm recency, ước lượng trên train.
- Mô hình tham chiếu: Logistic Regression; ứng viên phi tuyến: LightGBM.
- Thử riêng chu kỳ mua, thay đổi hoạt động, thành phần basket, discount và kích thước chuyến mua.
- Chu kỳ mua cải thiện Brier và log loss trong bốn fold backtest, nhưng lift chưa tăng đều.

Calibration và quy trình đánh giá POC

- LightGBM fit trên cutoff 180–439; sigmoid fit trên 453–481; chọn calibration trên 495–537.
- Quy tắc định trước: giữ sigmoid nếu log loss giảm ít nhất 0,001 và Brier không tăng.
- Cả hai phương án giữ xác suất thô; không refit model sau bước chọn calibration.
- Ứng viên chính: 18 feature + chu kỳ; 18 feature là phương án đối chứng.

Kết quả test tham khảo cho POC

Phương án	Brier ↓	Log loss ↓	ROC-AUC ↑	Lift tuần ↑
18 feature	0,16833	0,50547	0,82995	1,82242
18 + chu kỳ	0,16840	0,50546	0,82977	1,81804

- Hai phương án rất gần nhau; không dùng test đã xem để chọn lại feature.
- Lift tính top 10% từng cutoff, đồng điểm được xử lý bằng kỳ vọng chọn ngẫu nhiên.

Kịch bản xếp hạng trên validation

- Ở năng lực 10%, có 2.750 lượt household–cutoff qua 11 cutoff.
- Tỷ lệ mua ghi nhận: 96,58% theo LightGBM + chu kỳ, so với 70,82% kỳ vọng theo recency.
- Hai phương pháp dùng cùng giai đoạn fit đến cutoff 439; baseline recency có nhiều đồng điểm.
- Chênh lệch phản ánh xếp hạng, không phải giao dịch tăng thêm do can thiệp.

Deployment giả lập và kết luận

- Quy trình: dữ liệu đến cutoff $\rightarrow$ tính feature $\rightarrow$ pipeline đã lưu $\rightarrow$ xác suất và thứ hạng.
- Cutoff 711 tạo 2.500 dự báo cho ngày 712–718; nguồn không có nhãn để kiểm chứng.
- Cần theo dõi chất lượng nguồn, phân bố feature, calibration và hiệu quả theo thời gian khi có nhãn.
- POC cho thấy tín hiệu dự báo; hiệu quả kinh doanh và khả năng tổng quát hóa cần xác minh thêm.