Mục tiêu và phạm vi buổi báo cáo

Câu hỏi cần trả lời

- Bộ dữ liệu có những bảng nào, liên kết với nhau ra sao?
- Mỗi dòng, mỗi giỏ hàng và mỗi hộ đại diện cho điều gì?
- Những vấn đề chất lượng nào cần xử lý trước phân tích?
- Hành vi mua hàng thay đổi như thế nào theo thời gian và nhóm sản phẩm?

Lộ trình

1. Tổng quan dữ liệu và grain
2. Quy trình data preparation
3. Các phát hiện từ visualization
4. Giới hạn và việc cần xác nhận

Bài toán propensity là bối cảnh sử dụng; báo cáo này tập trung vào dữ liệu.

Bộ dữ liệu ở một trang

2.500	276.484	2.595.732	711
household	basket ID	dòng giao dịch	chỉ số ngày

Bối cảnh

Nhóm household mua sắm thường xuyên tại một retailer, với lịch sử mua khoảng hai năm. File local còn có product, demographic, campaign, coupon và thông tin trưng bày/gửi mail.

Nguồn: Audit local; dunnhumby Source Files — The Complete Journey.

Inventory: 8 bảng dữ liệu

Bảng	Số dòng	Nội dung / grain
transaction_data	2.595.732	Dòng sản phẩm trong basket của household
product	92.353	Danh mục sản phẩm, department và brand
hh_demographic	801	Thuộc tính household được cung cấp
campaign_table	7.208	Household gắn với campaign
campaign_desc	30	Mô tả và khoảng ngày của campaign
coupon	124.548	Ánh xạ coupon – sản phẩm – campaign
coupon_redempt	2.318	Sự kiện household sử dụng coupon
causal_data	36.786.524	Display/mailer theo product – store – week

Nguồn: dataset_inventory.csv; causal_data là tên bảng, không tự chứng minh quan hệ nhân quả.

Grain: một dòng không đồng nghĩa một lần đi mua

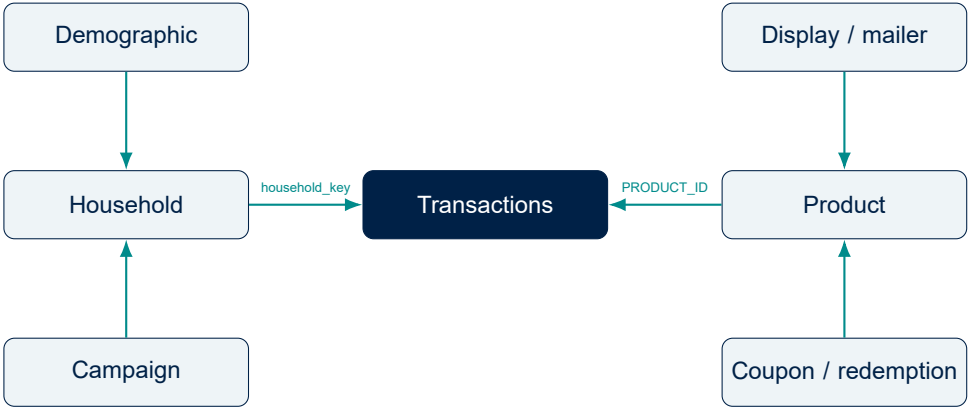


Ví dụ cấu trúc

household	basket	product
1	A	sữa
1	A	bánh
1	B	gạo

- 3 dòng sản phẩm, 2 basket, 1 household.
- Đếm basket bằng số `BASKET_ID` phân biệt.
- Một hộ có thể có nhiều basket trong một ngày.

Các bảng liên kết với nhau như thế nào?



Lưu ý join

Coupon là quan hệ nhiều-nhiều; display/mailer ở grain product–store–week. Không join trực tiếp khi chưa kiểm tra khóa, thời gian và nguy cơ nhân bản dòng.

Data preparation: từ 8 CSV đến bảng phân tích

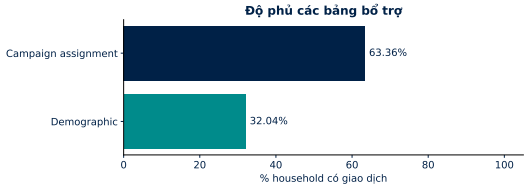
1. **Inventory:** số dòng, cột, kiểu dữ liệu, kích thước và grain.
2. **Schema:** chọn cột, xác định kiểu ID, ngày, số tiền; giữ nguyên dữ liệu nguồn.
3. **Quality:** kiểm tra null, duplicate, giá trị bất thường và tính nhất quán basket.
4. **Joins:** kiểm tra uniqueness, orphan keys và tỷ lệ match trước khi nối.
5. **Aggregation:** transaction line $\rightarrow$ basket $\rightarrow$ household-day.
6. **Visualization:** mô tả thời gian, số lượt mua, sản phẩm và độ phủ.

Nguyên tắc

Mọi bước đều giữ lại định nghĩa và mẫu số để người đọc có thể kiểm chứng.

Kiểm tra missing và độ phủ

- 12 cột transaction: không có ô null trong audit.
- Product join: 100% dòng transaction tìm thấy product.
- Chỉ 801 / 2.500 household có dòng demographic.
- Household không có demographic vẫn được giữ lại khi left join.



Nguồn: Audit local; campaign assignment không đồng nghĩa đã xem thông điệp.

Duplicate: kiểm tra theo grain, không xóa theo cảm tính

Phát hiện

- Transaction: 0 dòng trùng hoàn toàn trên 12 cột nguồn.
- Product: `PRODUCT_ID` duy nhất trong catalog.
- Coupon: 5.164 dòng trùng hoàn toàn trên 3 cột.

Cách xử lý

- Lưu duplicate report, giữ raw CSV không đổi.
- Với coupon mapping, chỉ deduplicate bản sao khi mục đích là tập mapping duy nhất và đã kiểm chứng semantics.
- Phân biệt trùng dòng và nhiều sản phẩm hợp lệ trong cùng basket.

Kiểm tra integrity trước khi join

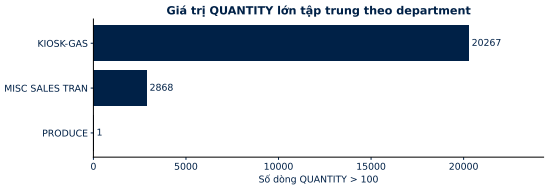
Kiểm tra	Kết quả	Diễn giải
Transaction product khớp catalog	100%	Join product many-to-one
Basket thuộc nhiều household	0	Một ID không bị chia sẻ giữa hộ
Basket thuộc nhiều ngày	0	Ngày nhất quán theo basket
Redemption có campaign được biết	100%	Kiểm tra khóa campaign
Redemption trong campaign window	100%	Kiểm tra ngày bắt đầu/kết thúc

Kiểm soát kỹ thuật

Dùng `validate="many_to_one"` khi join transaction–product; so sánh row count và tổng tiền trước/sau join.

Nguồn: Audit local; không suy ra mỗi event đã được quan sát đầy đủ chỉ từ join coverage.

Data quality: QUANTITY không cùng ý nghĩa giữa nhóm



- 23.136 dòng có `QUANTITY > 100`; maximum 89.638.
- Chủ yếu ở `KIOSK-GAS` và `MISC SALES TRAN`.
- Không cộng trực tiếp quantity giữa mọi department như số món.
- Cần xác nhận đơn vị với data owner; mô tả basket bằng số dòng và số sản phẩm phân biệt.

Nguồn: Tính trực tiếp sau join product; không giả định toàn bộ giá trị lớn là lỗi.

Basket 0 doanh số: giữ dữ liệu và đánh dấu

942

basket có tổng sales = 0

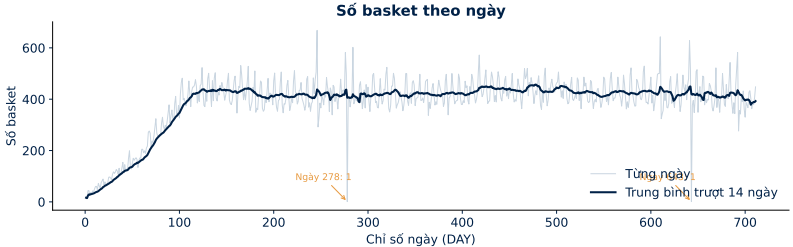
- 275.542 basket có tổng sales dương.
- 18.850 transaction lines có sales bằng 0.
- Một dòng 0 đồng không mặc nhiên là lỗi: có thể phản ánh khuyến mãi hoặc quy ước ghi nhận.

Quyết định chờ xác nhận

Định nghĩa “mua hàng hợp lệ” có bao gồm basket tổng sales bằng 0, fuel và miscellaneous transaction không?

Hiện trạng: báo cáo mô tả toàn bộ basket ghi nhận; không âm thầm loại 942 basket.

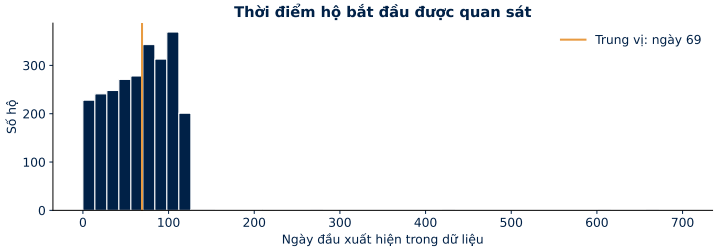
Visualization 1: basket theo ngày



- Đường nhạt: từng ngày; đường đậm: trung bình trượt 14 ngày.
- Các ngày đầu có lượng basket thấp hơn: cần xem cùng thời điểm household bắt đầu xuất hiện.
- Ngày 278 và 643 chỉ có 1 basket/ngày; cần kiểm tra nguyên nhân, không mặc định là lỗi hay ngày đóng cửa.

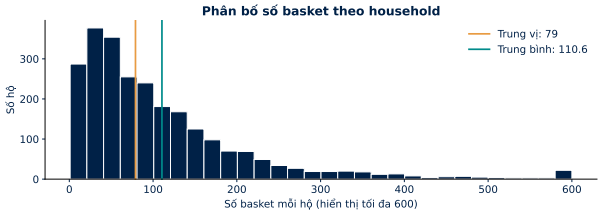
Nguồn: Transaction data; DAY là chỉ số tương đối, không có ngày lịch được xác nhận.

Visualization 2: household xuất hiện dần



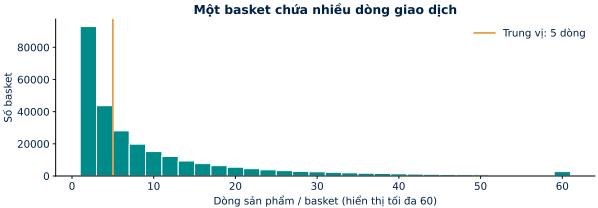
- Trung vị ngày xuất hiện đầu tiên là **69**; không phải mọi hộ đều quan sát từ ngày 1.
- Ngày xuất hiện đầu tiên không nhất thiết là ngày khách hàng gia nhập thực tế.
- Không suy diễn thời gian chưa được quan sát là không mua hoặc churn.

Visualization 3: vì sao có 276.484 basket?



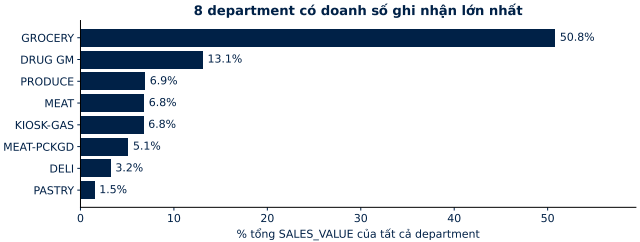
- 2.500 hộ được quan sát qua nhiều ngày; mỗi hộ có nhiều lần giao dịch.
- Trung vị **79**; trung bình **110,6** basket / hộ.
- 39.179 / 225.533 household-day có từ 2 basket trở lên.
- Biểu đồ giới hạn trục hiển thị ở 600; dữ liệu không bị cắt khi tính thống kê.

Visualization 4: một basket chứa bao nhiêu dòng?



- Trung vị: **5 dòng sản phẩm** / basket.
- Trung bình: khoảng **9,39 dòng** / basket.
- Một số basket lớn tạo đuôi phải; trục biểu đồ chặn hiển thị ở 60.
- Đếm dòng transaction sẽ lớn hơn số basket.

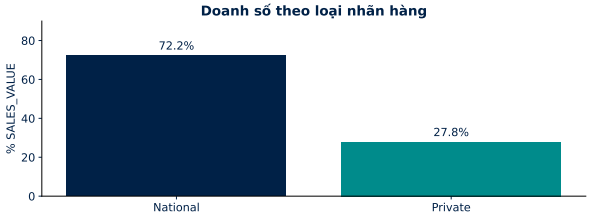
Visualization 5: doanh số ghi nhận theo department



Nguồn: Mẫu số: tổng SALES_VALUE toàn bộ department; hiển thị 8 department lớn nhất.

- GROCERY chiếm khoảng **50,8%** tổng `SALES_VALUE`.
- DRUG GM khoảng 13,1%; PRODUCE khoảng 6,9%.
- Fuel và miscellaneous cũng hiện diện: “any basket” rộng hơn grocery.

Visualization 6: cơ cấu nhãn hàng



- National khoảng **72,2%**; private khoảng **27,8%** doanh số ghi nhận.
- Brand là thuộc tính product, cần kiểm tra khóa trước join.
- Đây là cơ cấu doanh số của mẫu dữ liệu, không chứng minh sở thích của toàn thị trường.

Campaign, coupon và media: có gì và cần thận trọng gì?

Nguồn	Có thể mô tả	Điểm cần kiểm tra
Campaign	63,36% household có assignment	Assignment không chứng minh exposure.
Coupon / redemption	2.318 redemption events	Mapping nhiều-nhiều; duplicate coupon rows.
Display / mailer	36,79 triệu dòng product–store–week	Không tự coi là exposure cá nhân; kiểm tra thời điểm availability.
Demographic	801 household có thông tin	Thiếu 67,96%; thời điểm hiệu lực chưa rõ.

Phân biệt quan trọng

Dữ liệu quan sát hỗ trợ mô tả và đặt giả thuyết; không tự chứng minh campaign hoặc coupon gây ra mua hàng.

Kết luận và những điểm cần thống nhất

Đã hiểu rõ

- Grain, khóa và quan hệ giữa 8 bảng.
- Transaction không thiếu giá trị; product match 100%.
- Basket lặp theo household và thời gian.
- Có khác biệt rõ về department, brand và độ phủ bảng bổ trợ.

Cần xác nhận

- Quy tắc giao dịch mua hợp lệ: zero sales / fuel / miscellaneous.
- Ý nghĩa và đơn vị của `QUANTITY` theo department.
- Nguyên nhân ngày 278 và 643 chỉ có một basket.
- Ngày lịch, khả năng quan sát ngoài retailer và thời điểm cập nhật demographic.
- Quyền sử dụng và chia sẻ dữ liệu.

Nguồn: Dữ liệu local: `sample_data/dunnhumby`; audit: `artifacts/propensity_v2/data_understanding`; mô tả nguồn chính thức.