TỔNG QUAN VÀ CHUẨN BỊ

DỮ LIỆU DUNNHUMBY

Khảo sát chất lượng và trực quan hóa dữ liệu bán lẻ

[Tên người trình bày] | [Ngày báo cáo]

Mục tiêu và phạm vi nghiên cứu

Câu hỏi cần trả lời

- Bộ dữ liệu có những bảng nào, liên kết với nhau ra sao?
- Mỗi dòng, mỗi giỏ hàng và mỗi hộ đại diện cho điều gì?
- Những vấn đề chất lượng nào cần xử lý trước phân tích?
- Hành vi mua hàng thay đổi như thế nào theo thời gian và nhóm sản phẩm?

Lộ trình

1. Tổng quan dữ liệu và grain
2. Quy trình data preparation
3. Các phát hiện từ visualization
4. Giới hạn và việc cần xác nhận

Bài toán propensity là bối cảnh sử dụng; báo cáo này tập trung vào dữ liệu.

Tổng quan quy mô bộ dữ liệu

2.500	276.484	2.595.732	711
household	basket ID	dòng giao dịch	chỉ số ngày

Bối cảnh

Nhóm household mua sắm thường xuyên tại một retailer, với lịch sử mua khoảng hai năm. File local còn có product, demographic, campaign, coupon và thông tin trưng bày/gửi mail.

Nguồn: Audit local; dunnhumby Source Files — The Complete Journey.

Danh mục tám bảng dữ liệu

Bảng	Số dòng	Nội dung / grain
transaction_data	2.595.732	Dòng sản phẩm trong basket của household
product	92.353	Danh mục sản phẩm, department và brand
hh_demographic	801	Thuộc tính household được cung cấp
campaign_table	7.208	Household gắn với campaign
campaign_desc	30	Mô tả và khoảng ngày của campaign
coupon	124.548	Ánh xạ coupon – sản phẩm – campaign
coupon_redempt	2.318	Sự kiện household sử dụng coupon
causal_data	36.786.524	Display/mailer theo product – store – week

Nguồn: dataset_inventory.csv; causal_data là tên bảng, không tự chứng minh quan hệ nhân quả.

Đơn vị quan sát và cấp độ dữ liệu

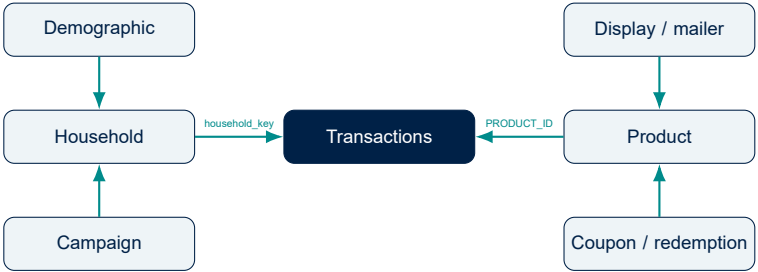


Ví dụ cấu trúc

household	basket	product
1	A	sữa
1	A	bánh
1	B	gạo

- 3 dòng sản phẩm, 2 basket, 1 household.
- Đếm basket bằng số `BASKET_ID` phân biệt.
- Một hộ có thể có nhiều basket trong một ngày.

Cấu trúc liên kết giữa các bảng dữ liệu



Hàm ý đối với kết nối dữ liệu

Coupon tạo quan hệ nhiều-nhiều; display/mailer có cấp độ product–store–week. Quá trình kết nối cần bảo toàn cấp độ quan sát và kiểm tra số dòng sau join.

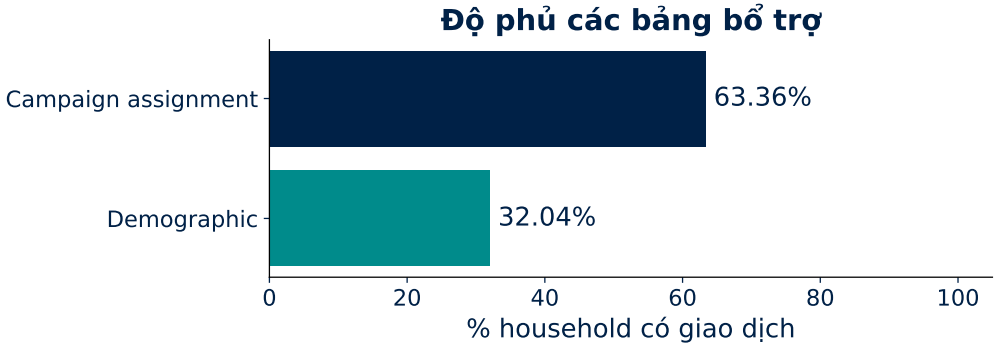
Quy trình chuẩn bị dữ liệu

1. **Inventory:** số dòng, cột, kiểu dữ liệu, kích thước và grain.
2. **Schema:** chọn cột, xác định kiểu ID, ngày, số tiền; giữ nguyên dữ liệu nguồn.
3. **Quality:** kiểm tra null, duplicate, giá trị bất thường và tính nhất quán basket.
4. **Joins:** kiểm tra uniqueness, orphan keys và tỷ lệ match trước khi nối.
5. **Aggregation:** transaction line $\rightarrow$ basket $\rightarrow$ household-day.
6. **Visualization:** mô tả thời gian, số lượt mua, sản phẩm và độ phủ.

Kết quả đầu ra

Các bảng thống kê có đơn vị quan sát, khóa liên kết và mẫu số được xác định rõ.

Kiểm tra dữ liệu thiếu và độ bao phủ



- **Kết quả:** transaction không có ô null; 801 / 2.500 hộ có demographic.
- **Hàm ý:** dùng left join để giữ các hộ không có thông tin nhân khẩu học.

Nguồn: Audit local; mẫu số là 2.500 household có giao dịch.

Kiểm tra dữ liệu trùng lặp

Phát hiện

- Transaction: 0 dòng trùng hoàn toàn trên 12 cột nguồn.
- Product: `PRODUCT_ID` duy nhất trong catalog.
- Coupon: 5.164 dòng trùng hoàn toàn trên 3 cột.

Hàm ý xử lý

- Giữ dữ liệu gốc và ghi nhận số dòng trùng trong báo cáo chất lượng.
- Đánh giá 5.164 dòng coupon theo cấp độ mapping trước khi loại trùng.
- Xác định trùng lặp trên đúng đơn vị quan sát của từng bảng.

Kiểm tra tính toàn vẹn trước khi kết nối dữ liệu

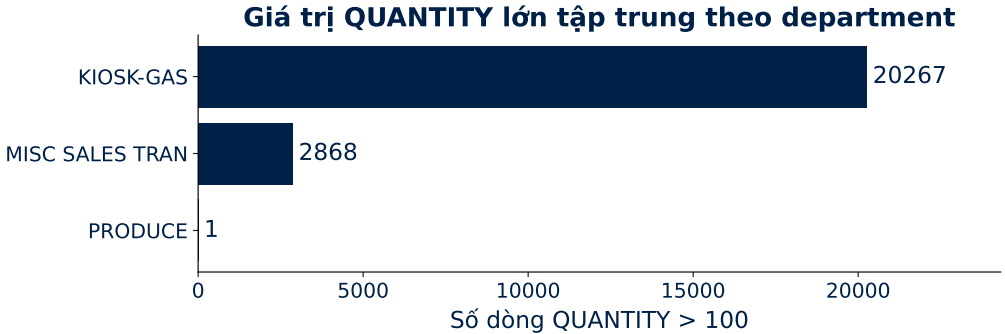
Kiểm tra	Kết quả	Diễn giải
Transaction product khớp catalog	100%	Join product many-to-one
Basket thuộc nhiều household	0	Một ID không bị chia sẻ giữa hộ
Basket thuộc nhiều ngày	0	Ngày nhất quán theo basket
Redemption có campaign được biết	100%	Kiểm tra khóa campaign
Redemption trong campaign window	100%	Kiểm tra ngày bắt đầu/kết thúc

Hàm ý phân tích

Khóa sản phẩm trong catalog duy nhất và match toàn bộ transaction; quan hệ này cho phép kết nối nhiều-một, đồng thời đối chiếu số dòng trước/sau join.

Nguồn: Audit local; kiểm tra khóa và khoảng ngày trên các bảng được cung cấp.

Phân bố QUANTITY và vấn đề đơn vị đo



- **Kết quả:** 23.136 dòng có `QUANTITY > 100`, tập trung ở fuel/misc.
- **Diễn giải:** user guide mô tả lượng mua, nhưng không nêu đơn vị riêng cho fuel; chưa tổng hợp xuyên nhóm.

Nguồn: Audit transaction–product; The Complete Journey User Guide, trang 3.

Kiểm tra giỏ hàng có doanh số bằng không

942

basket có tổng sales = 0

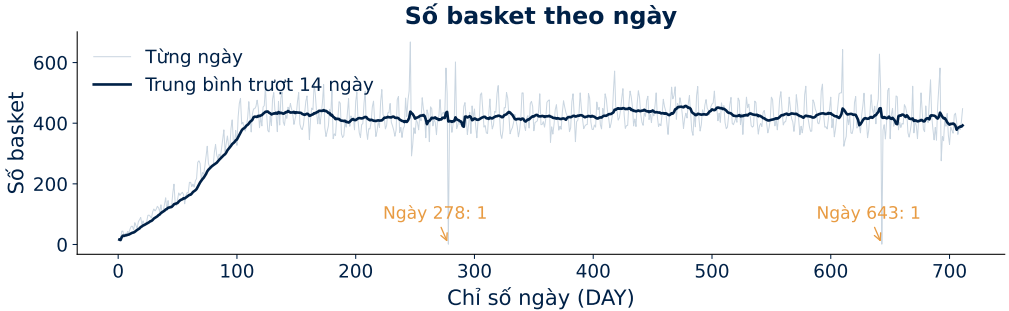
- 275.542 basket có tổng sales dương.
- 18.850 transaction lines có sales bằng 0.
- Một dòng 0 đồng không mặc nhiên là lỗi: có thể phản ánh khuyến mãi hoặc quy ước ghi nhận.

Hàm ý đối với định nghĩa mua hàng

Số giỏ được xác định phụ thuộc vào quy tắc đưa basket zero-sales, fuel và miscellaneous vào phạm vi phân tích.

Phạm vi hiện tại: thống kê mô tả bao gồm toàn bộ basket được ghi nhận.

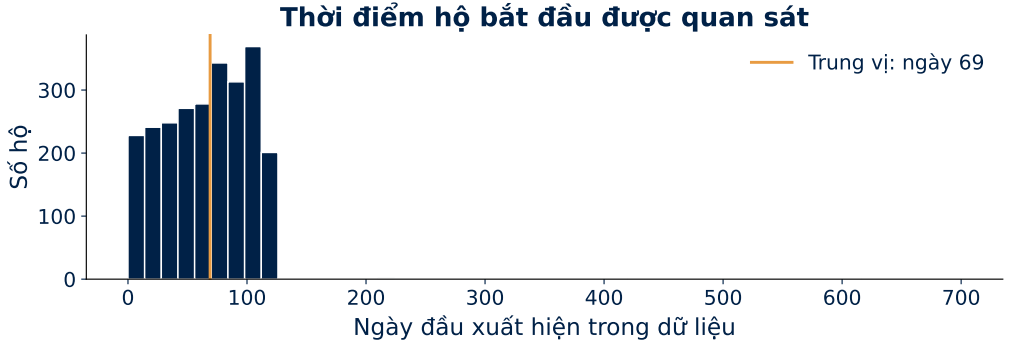
Phân bố số giỏ hàng theo ngày



- **Kết quả:** hoạt động tăng ở giai đoạn đầu; ngày 278 và 643 chỉ có 1 basket/ngày.
- **Diễn giải:** hai điểm giảm sâu có nguyên nhân chưa xác định; đường đậm là trung bình 14 ngày.

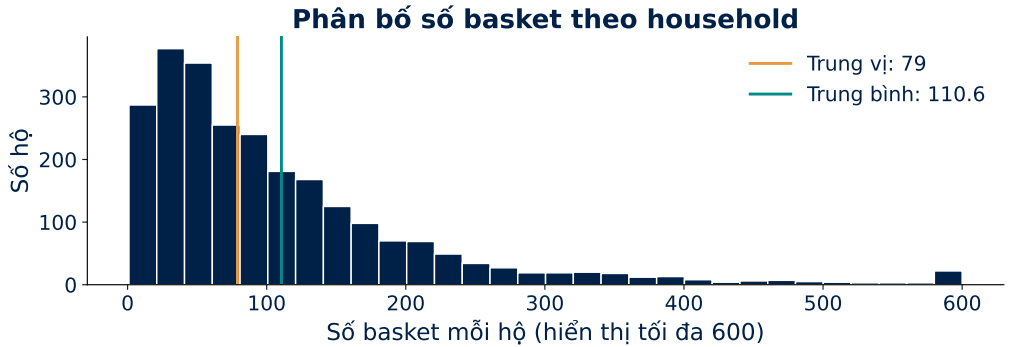
Nguồn: Transaction data; DAY là chỉ số tương đối, không có ngày lịch được xác nhận.

Phân bố thời điểm xuất hiện đầu tiên của hộ



- **Kết quả:** trung vị ngày xuất hiện đầu tiên là **69**.
- **Diễn giải:** thời gian quan sát khác nhau giữa các hộ; ngày xuất hiện không nhất thiết là ngày gia nhập.

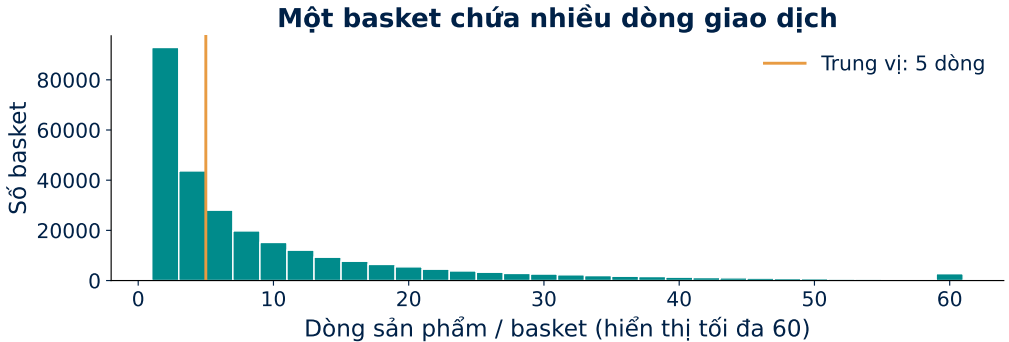
Phân bố số giỏ hàng theo hộ gia đình



- **Kết quả:** trung vị **79**, trung bình **110,6** basket / hộ.
- **Diễn giải:** phân bố lệch phải; 39.179 household-day có từ 2 basket trở lên.

Nguồn: Giới hạn hiển thị: 600 basket/hộ; thống kê tính trên dữ liệu đầy đủ.

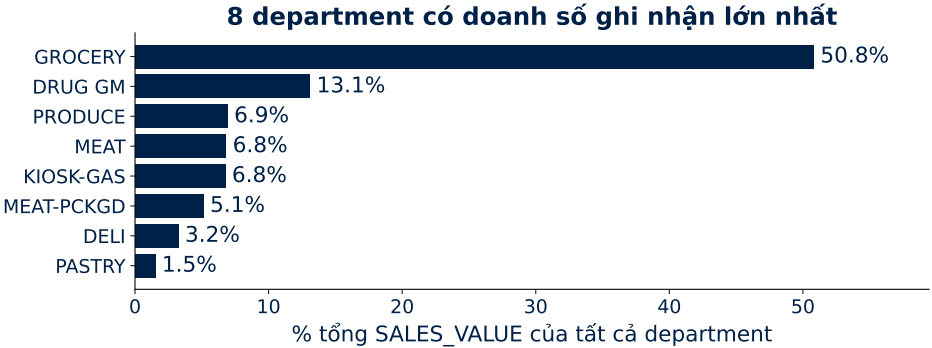
Phân bố số dòng sản phẩm trong giỏ hàng



- **Kết quả:** trung vị **5 dòng**, trung bình **9,39 dòng** / basket.
- **Diễn giải:** một số basket lớn tạo đuôi phải; dòng sản phẩm và basket có cấp độ khác nhau.

Nguồn: Giới hạn hiển thị: 60 dòng/basket; thống kê tính trên dữ liệu đầy đủ.

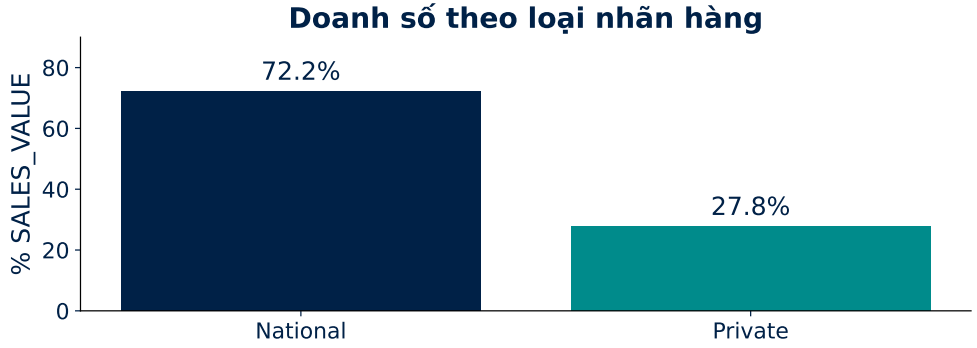
Cơ cấu doanh số ghi nhận theo nhóm hàng



- **Kết quả:** GROCERY chiếm **50,8%**; DRUG GM 13,1%; PRODUCE 6,9%.
- **Diễn giải:** cơ cấu giao dịch bao gồm cả fuel và miscellaneous ngoài grocery.

Nguồn: Tổng SALES_VALUE retailer nhận được; hiển thị 8 department lớn nhất. User Guide, trang 3.

Cơ cấu doanh số ghi nhận theo loại nhãn hàng



- **Kết quả:** National chiếm **72,2%**; private chiếm **27,8%**.
- **Diễn giải:** đây là cơ cấu SALES_VALUE trong mẫu household được cung cấp.

Dữ liệu chiến dịch, coupon và hoạt động truyền thông

Nguồn	Kết quả quan sát	Cấp độ thông tin
Campaign	63,36% household có assignment	Household–campaign.
Coupon / redemption	2.318 redemption events	Household–coupon–ngày.
Display / mailer	36,79 triệu dòng	Product–store–week.
Demographic	801 household có thông tin	Household; không bao phủ toàn bộ mẫu.

Hàm ý nghiên cứu

Các bảng bổ sung bối cảnh mua sắm ở nhiều cấp độ; dữ liệu quan sát hỗ trợ mô tả và xây dựng giả thuyết.

Kết luận và các vấn đề cần xác minh

Kết quả chính

- Grain, khóa và quan hệ giữa 8 bảng.
- Transaction không thiếu giá trị; product match 100%.
- Basket lặp theo household và thời gian.
- Có khác biệt rõ về department, brand và độ phủ bảng bổ trợ.

Giới hạn và hướng nghiên cứu

- Kiểm chứng định nghĩa giao dịch mua và đơn vị `QUANTITY`.
- Đối chiếu hai ngày có lượng giao dịch thấp với nguồn dữ liệu.
- Bổ sung thông tin ngày lịch và thời điểm ghi nhận demographic nếu có.
- Đánh giá giới hạn đại diện và phạm vi quan sát của mẫu.

Nguồn: Dữ liệu local: `sample_data/dunnhumby`; audit: `artifacts/propensity_v2/data_understanding`; mô tả nguồn chính thức.

Phụ lục A1: Giao dịch — khóa và thời gian

Field	Định nghĩa và cách đọc
household_key	Mã định danh household có giao dịch.
BASKET_ID	Mã basket/giao dịch; nhiều dòng sản phẩm có thể cùng một basket.
DAY	Chỉ số ngày tương đối trong dữ liệu; không phải ngày lịch đã xác nhận.
PRODUCT_ID	Mã sản phẩm trên dòng giao dịch; dùng nối với bảng product.
STORE_ID	Mã cửa hàng ghi nhận giao dịch.
TRANS_TIME	Giờ giao dịch dạng số HHMM; ví dụ 1631 là 16:31.
WEEK_NO	Chỉ số tuần của giao dịch; không tự suy diễn là tuần lịch.

Nguồn: Grain: một dòng sản phẩm trong basket; audit local: 2.595.732 dòng.

Phụ lục A2: Giao dịch — số lượng và giá trị

Field	Định nghĩa và ý nghĩa phân tích
QUANTITY	Lượng sản phẩm mua trong chuyến mua; đơn vị riêng của fuel chưa được nêu trong user guide.
SALES_VALUE	Số tiền retailer nhận được từ dòng sản phẩm; không nhất thiết bằng số tiền khách trả.
RETAIL_DISC	Giá trị điều chỉnh/chiết khấu bán lẻ; thường mang dấu âm trong dữ liệu.
COUPON_DISC	Giá trị điều chỉnh/chiết khấu coupon được ghi nhận trên dòng.
COUPON_MATCH_DISC	Giá trị điều chỉnh coupon matching được ghi nhận trên dòng.

Cơ sở định nghĩa

User guide phân biệt số tiền retailer nhận được và số tiền khách trả khi sử dụng manufacturer coupon.

Nguồn: The Complete Journey User Guide, trang 3.

Phụ lục B: Từ điển trường dữ liệu sản phẩm

Field	Định nghĩa và cách đọc
PRODUCT_ID	Mã sản phẩm; khóa nối với transaction và coupon.
MANUFACTURER	Mã nhà sản xuất được cung cấp trong catalog.
DEPARTMENT	Nhóm hàng cấp department; ví dụ GROCERY, PRODUCE.
BRAND	Phân loại nhãn hàng; trong dữ liệu có National và Private.
COMMODITY_DESC	Mô tả nhóm hàng ở cấp commodity.
SUB_COMMODITY_DESC	Mô tả nhóm hàng chi tiết hơn dưới commodity.
CURR_SIZE_OF_PRODUCT	Mô tả quy cách/kích cỡ sản phẩm; ví dụ 22 LB.

Nguồn: 92.353 dòng; PRODUCT_ID không trùng trong catalog local.

Phụ lục C: Từ điển trường dữ liệu nhân khẩu học

Field	Nội dung nhìn thấy trong file local
household_key	Mã household; khóa nối với transaction.
classification_1	Nhóm được mã hóa bằng nhãn Age Group1–Age Group6.
classification_2	Nhóm phân loại mã hóa; các giá trị gồm X, Y, Z.
classification_3	Nhóm phân loại mã hóa bằng các nhãn Level.
classification_4	Nhóm phân loại mã hóa dạng số; ý nghĩa cần xác nhận.
classification_5	Nhóm phân loại mã hóa bằng các nhãn Group.
HOMEOWNER_DESC	Nhãn mô tả tình trạng nhà ở/sở hữu nhà, có giá trị Unknown.
KID_CATEGORY_DESC	Nhãn nhóm trẻ em trong hộ, gồm None/Unknown.

Nguồn: 801 household; không tự gán nghĩa cho các mã classification khi chưa có data dictionary.

Phụ lục D: Từ điển trường phân bổ chiến dịch

Field	Định nghĩa và cách đọc
DESCRIPTION	Nhãn loại campaign trong bảng, ví dụ TypeA.
household_key	Mã household được liên kết với campaign.
CAMPAIGN	Mã campaign; nối với campaign_desc.

Đơn vị quan sát

Một dòng biểu diễn liên kết household–campaign. Có assignment không chứng minh hộ đã nhận, mở hoặc tương tác với thông điệp.

Phụ lục E: Từ điển trường mô tả chiến dịch

Field	Định nghĩa và cách đọc
DESCRIPTION	Nhãn loại campaign, ví dụ TypeB.
CAMPAIGN	Mã campaign; nối với campaign assignment hoặc redemption.
START_DAY	Chỉ số ngày bắt đầu campaign theo dữ liệu nguồn.
END_DAY	Chỉ số ngày kết thúc campaign theo dữ liệu nguồn.

Ý nghĩa phân tích

Hai chỉ số ngày xác định khoảng hoạt động của chiến dịch và hỗ trợ đối chiếu thời điểm redemption.

Phụ lục F: Từ điển trường dữ liệu coupon

Field	Định nghĩa và cách đọc
COUPON_UPC	Mã coupon; nối với sự kiện trong coupon_redempt.
PRODUCT_ID	Mã sản phẩm được liên kết với coupon.
CAMPAIGN	Mã campaign gắn với mapping coupon–product.

Đơn vị quan sát và kết quả kiểm tra

Bảng mô tả mapping coupon–product–campaign. Có 5.164 dòng trùng hoàn toàn trên ba cột.

Phụ lục G: Từ điển trường sử dụng coupon

Field	Định nghĩa và cách đọc
household_key	Household có sự kiện redemption.
DAY	Chỉ số ngày ghi nhận sự kiện sử dụng coupon.
COUPON_UPC	Mã coupon được sử dụng; nối với bảng coupon.
CAMPAIGN	Mã campaign liên quan tới redemption.

Đơn vị quan sát

Một dòng mô tả sự kiện sử dụng coupon của household trong một campaign, tại một ngày được ghi nhận.

Phụ lục H: Từ điển trưng bày và mailer

Field	Định nghĩa và cách đọc
PRODUCT_ID	Mã sản phẩm trong bản ghi trưng bày/marketing.
STORE_ID	Mã cửa hàng của bản ghi.
WEEK_NO	Chỉ số tuần của bản ghi.
display	Mã trưng bày tại cửa hàng; cần bảng giải mã từ nguồn.
mailer	Mã mailer; cần bảng giải mã từ nguồn.

Đơn vị quan sát

Bản ghi kết hợp sản phẩm, cửa hàng và tuần; các mã mô tả hình thức trưng bày và mailer.

Nguồn: 36.786.524 dòng local; diễn giải mã display/mailer cần tài liệu gốc.